

Реализация мультимодальных регуляризованных тематических моделей в библиотеке с открытым кодом BigARTM

Мурат Апишев
great-mel@yandex.ru

МГУ им. М. В. Ломоносова, фак-т ВМК

16 апреля 2015

Тематическое моделирование

Тематическое моделирование — одно из приложений машинного обучения к анализу текстов.

Дано: Корпус текстов D со словарём W в виде матрицы «слова – документы» F (Bag-of-words). На пересечении строки и столбца — вероятность встретить слово w в документе d .

Найти: Множество тем, описывающих D , т.е. матричное разложение $F = \Phi_{W \times T} \times \Theta_{T \times D}$.

$\phi_{wt} = p(w|t)$ — вероятность того, что слово w относится к теме t ,
 $\theta_{td} = p(t|d)$ — вероятность того, что документ d описывает тему t .

$$p(w|d) = \sum_t p(w|t)p(t|d)$$

Тематическое моделирование

$$p(w|d) = \sum_t p(w|t)p(t|d)$$



Разработан спектрально-аналитический подход к выявлению размытых протяженных повторов в геномных последовательностях. Метод основан на разномасштабном оценивании сходства нуклеотидных последовательностей в пространстве коэффициентов разложения фрагментов кривых GC- и GA-содержания по классическим ортогональным базисам. Найдены условия оптимальной аппроксимации, обеспечивающие автоматическое распознавание повторов различных видов (прямых и инвертированных, а также tandemных) на спектральной матрице сходства. Метод одинаково хорошо работает на разных масштабах данных. Он позволяет выявлять следы сегментных дупликаций и мегасателлитные участки в геноме, районы синтезии при сравнении пары геномов. Его можно использовать для детального изучения фрагментов хромосом (поиска размытых участков с умеренной длиной повторяющегося паттерна).

Аддитивная регуляризация тематических моделей

АРТМ¹ — один из подходов к регуляризации процесса обучения тематических моделей.

Для нахождения матричного разложения будем максимизировать логарифм правдоподобия коллекции. Задача некорректно поставленная и должна быть регуляризована:

$$L(\Phi, \Theta) + R(\Phi, \Theta) = \sum_{d \in D} \sum_{w \in d} n_{dw} \ln \sum_{t \in T} \phi_{wt} \theta_{td} + R(\Phi, \Theta) \rightarrow \max_{\Phi, \Theta},$$

где n_{dw} — число раз, которое слово w встретилось в документе d .

Ограничения неотрицательности и нормировки

$$\phi_{wt} \geq 0; \quad \sum_{w \in W} \phi_{wt} = 1; \quad \theta_{td} \geq 0; \quad \sum_{d \in D} \theta_{td} = 1.$$

Регуляризаторы — это дополнительные ограничения на правдоподобие, позволяющие получить модель с нужными свойствами.

¹ Воронцов К. В. Аддитивная регуляризация тематических моделей коллекций текстовых документов. Доклады РАН. 2014.

Vorontsov K. V., Potapenko A. A. Tutorial on Probabilistic Topic Modeling: Additive Regularization for Stochastic Matrix Factorization. AIST. 2014

Основная теорема АРТМ

Теорема

Если функция $R(\Phi, \Theta)$ стохастических матриц Φ, Θ непрерывно дифференцируема и (Φ, Θ) является точкой локального максимума функции $L(\Phi, \Theta) + R(\Phi, \Theta)$, то для любой темы t и документа d выполняется система уравнений:

$$p_{tdw} = \frac{\phi_{wt}\theta_{td}}{\sum_{s \in T} \phi_{ws}\theta_{sd}}; \quad n_{wt} = \sum_{d \in D} n_{dw} p_{tdw}; \quad n_{td} = \sum_{w \in d} n_{dw} p_{tdw};$$


$$\phi_{wt} \propto \left(n_{wt} + \phi_{wt} \frac{\partial R}{\partial \phi_{wt}} \right)_+; \quad \theta_{td} \propto \left(n_{td} + \theta_{td} \frac{\partial R}{\partial \theta_{td}} \right)_+.$$

Данная задача может быть решена с помощью регуляризованного EM-алгоритма.

Мультимодальные тематические модели


Дана текстовая коллекция D , тематическое моделирование ищет:

$p(t|d)$ — распределение по темам документа d ,
 $p(w|t)$ — распределение слов в теме t .




Мультимодальные тематические модели

М-АРТМ ищет распределения по темам $p(w|t)$, авторов $p(a|t)$, меток времени $p(y|t)$,




Мультимодальные тематические модели

М-АРТМ ищет распределения по темам $p(w|t)$, авторов $p(a|t)$,
меток времени $p(y|t)$, **объектов на картинках $p(o|t)$** ,




Мультимодальные тематические модели

М-АРТМ ищет распределения по темам $p(w|t)$, авторов $p(a|t)$,
меток времени $p(y|t)$, объектов на картинках $p(o|t)$,
связанных документов $p(d'|t)$,




Мультимодальные тематические модели

М-АРТМ ищет распределения по темам $p(w|t)$, авторов $p(a|t)$,
меток времени $p(y|t)$, объектов на картинках $p(o|t)$,
связанных документов $p(d'|t)$, **рекламных баннеров** $p(b|t)$,




Мультимодальные тематические модели

М-АРТМ ищет распределения по темам $p(w|t)$, авторов $p(a|t)$,
меток времени $p(y|t)$, объектов на картинках $p(o|t)$,
связанных документов $p(d'|t)$, рекламных баннеров $p(b|t)$,
пользователей $p(u|t)$,



Мультимодальные тематические модели

М-АРТМ ищет распределения по темам $p(w|t)$, авторов $p(a|t)$,
меток времени $p(y|t)$, объектов на картинках $p(o|t)$,
связанных документов $p(d'|t)$, рекламных баннеров $p(b|t)$,
пользователей $p(u|t)$,
и объединяет все модальности в одну тематическую модель.



Мультимодальные тематические модели

Правдоподобие для мультимодальной модели примет вид

$$Q(\Phi, \Theta) = \sum_{j=1}^m \tau^j \sum_{d \in D} \sum_{x \in X_j} n_{dx}^j \ln \sum_{t \in T} \phi_{xt}^j \theta_{td} \rightarrow \max$$

τ^j — коэффициент, регулирующий значимость j -й модальности в модель.

Теорема

Если функция $R(\Phi, \Theta)$ стохастических матриц $\Phi^j, j = 1, \dots, m$, Θ непрерывно дифференцируема и (Φ, Θ) является точкой локального максимума функции $Q(\Phi, \Theta) + R(\Phi, \Theta)$, то для любой темы t и документа d выполняется система уравнений:

$$p_{tdw}^j = \frac{\phi_{xt}^j \theta_{td}}{\sum_{s \in T} \phi_{xs}^j \theta_{sd}}; \quad n_{xt}^j = \sum_{d \in D} n_{dx}^j p_{tdx}^j; \quad n_{td}^j = \sum_{x \in d, x \in W^j} n_{dx}^j p_{tdx}^j;$$

$$\phi_{xt}^j \propto \left(n_{xt}^j + \phi_{xt}^j \frac{\partial R}{\partial \phi_{xt}^j} \right)_+; \quad \theta_{td} \propto \left(\sum_{j=1}^m \tau^j n_{td}^j + \theta_{td} \frac{\partial R}{\partial \theta_{td}} \right)_+.$$

BigARTM: особенности

BigARTM² — библиотека с открытым кодом для построения мультимодальных регуляризованных тематических моделей больших коллекций текстов.


- ❶ Эффективная параллельная и онлайновая обработка данных.
- ❷ Кросплатформенность (Windows, Linux, Mac OS X).
- ❸ Ядро на C++, API на C++ и Python.

²<http://bigartm.org>

BigARTM: архитектура

Параллелизм BigARTM основан на многопоточности.

- Множество обработчиков (Processor).
- Один поток слияния (Merger)
- Очередь заданий, откуда обработчики берут данные.
- Очередь слияния, в которую обработчики помещают результаты, и из которой их забирает поток слияния.



BigARTM vs. VW.LDA vs. Gensim

Библиотека	Число процессоров	Время обучения модели ³
BigARTM	1	35 минут
LdaModel	1	369 минут
VW.LDA	1	73 минуты
BigARTM	4	9 минут
LdaMulticore	4	60 минут
BigARTM	8	4.5 минуты
LdaMulticore	8	57 минут

³Использовалась коллекция документов английской Википедии,
 $|D| \approx 3.7 \times 10^6$. Вычисления производились в облаке Amazon EC2.

Реализация механизма регуляризации

- ❶ Механизм регуляризации реализован как для матрицы Θ , так и для Φ .
- ❷ В первом случае регуляризирующие поправки вычисляются для каждого документа (т. е. для вектор-столбцов Θ) во время его обработки.
- ❸ Регуляризация Φ производится каждый раз при её обновлении.
- ❹ Каждый регуляризатор — плагин на C++, пользователь всегда может написать новый и добавить его в библиотеку по описанной схеме.

Список регуляризаторов

Реализованы следующие регуляризаторы:

- **Сглаживание и разреживание матрицы Θ .** Сглаживает/разреживает θ_d распределением α . Формула M-шага:

$$\theta_{td} \propto (n_{td} + \alpha_0 \alpha_t)_+$$

- **Сглаживание и разреживание матрицы Φ .** Сглаживает/разреживает ϕ_t распределением β . Формула M-шага:

$$\phi_{wt} \propto (n_{wt} + \beta_0 \beta_w)_+$$

- **Декорелирование тем в матрице Φ .** Разреживает темы, делая их как можно более различными. Формула M-шага:

$$\phi_{wt} \propto \left(n_{wt} - \rho \phi_{wt} \sum_{s \in T \setminus t} \phi_{ws} \right)_+$$

- **Label Regularization Φ .** Приближает оценку распределения слов, полученную моделью, к частотным, полученным по коллекции. Пусть \hat{p}_w — частота слова w в выборке. Формула M-шага:

$$\phi_{wt} \propto \left(n_{wt} + \tau \hat{p}_w \frac{\phi_{wt} n_t}{\sum_{s \in T} \phi_{ws} n_w} \right)_+.$$

Реализация мультимодальных моделей

- ① Модифицирован способ хранения матрицы Φ .
- ② Реализовано хранение метки модальности для каждого слова из словаря.
- ③ Реализована раздельная нормировка подматриц Φ^j по модальностям.
- ④ Реализован API для регуляризаторов отдельных модальностей.
- ⑤ Сделанные модификации не ухудшили производительность.

Описание эксперимента с регуляризацией

- Производилось сравнение моделей LDA и ARTM.
- Эксперименты ставились на коллекции Wikipedia,
 $\approx 3.7 \times 10^6$ документов, объём словаря $\approx 2 \times 10^5$ слов.
- Онлайн-алгоритм (один проход по коллекции)


Метрики качества

- Перплексия


$$\mathcal{P}(D) = \exp\left(-\frac{1}{n}\mathcal{L}(\Phi, \Theta)\right) = \exp\left(-\frac{1}{n}\sum_{d \in D} \sum_{w \in d} n_{dw} \ln p(w|d)\right)$$

- Разреженности матриц Φ и Θ
- Характеристики ядер тем: если для слова вероятность $p(t|w)$ больше некоторого порога в теме t — относим его к ядру W_t этой темы. Характеристики:
 - ① Размер: $|W_t|$
 - ② Чистота: $\sum_{t \in W_t} p(w|t)$
 - ③ Контрастность: $|W_t|^{-1} \sum_{t \in W_t} p(t|w)$

Результаты: перплексия и разреженности



Результаты: характеристики ядер тем



Описание эксперимента с классификацией

- При наличии в документах модальности меток классов можно обучить тематическую модель классификации.
- В общем случае тематическим моделям пока не удается обойти традиционные алгоритмы классификации, такие как SVM.
- Но в случае сложных задач с большим числом несбалансированных, пересекающихся и взаимозависимых классов ситуация меняется⁴.
- В данном эксперименте используется коллекция EUR-lex. Параметры (после предобработки): ≈ 19000 документов, ≈ 21000 слов в словаре, ≈ 3200 классов.
- В статье [Rubin 2012] производилось сравнение алгоритма Dependency LDA и SVM. Сравниваемся с обоими по метрикам из статьи.

⁴ «T. N. Rubin, A. Chambers, P. Smyth, and M. Steyvers. Statistical topic models for multi-label document classification, 2012».

Метрики и результаты

Используемые метрики качества классификации:

- Площадь под кривой precision-recall (AUC_{PR}).
- Площадь по ROC-кривой (AUC_{ROC}).
- Доля документов, у которых самая вероятная метка неверная (One Error).
- Доля документов, не классифицированных полностью правильно (Is Error).

	$ T _{optimal}$	$AUC_{PR} \uparrow$	$AUC_{ROC} \uparrow$	$One\ Error \downarrow$	$Is\ Error \downarrow$
ARTM	10000	0.513	0.980	29.1	95.5
DLDA	200	0.492	0.982	32.0	97.2
SVM _{best}	≈ 21000	0.435	0.975	31.6	98.1

Выводы

- APTM даёт возможность легко строить тематические модели, удовлетворяющие большому количеству ограничений.
- M-APTM позволяет строить тематические модели, учитывающие всю необходимую метаинформацию.
- BigARTM — параллельная реализация онлайнового EM-алгоритма для построения мультимодальных тематических моделей с возможностью комбинирования регуляризаторов.
- В экспериментах на больших коллекциях BigARTM показывает высокую производительность и качество.