Требования к NLP-специалистам в индустрии

Мурат Апишев (mel-lain@yandex.ru)

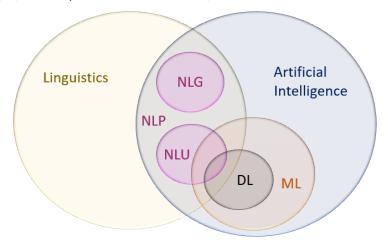
Февраль, 2022

О чем пойдет речь

- ▶ Предметная область и профессия:
 - ▶ профессия NLP-специалиста, задачи
 - смежные специальности, отличия
- Требования к специалистам:
 - Стажер / джуниор
 - ▶ Мидл
 - Синьор
 - Тимлид
 - Развитие специалиста
- Тренды отрасли
- ▶ Вопросы из собеседований:
 - ▶ Примеры вопросов с ответами из различных секций
 - ▶ Прочие вопросы, типичные ошибки

Профессия NLP-специалиста

- ▶ С развитием отрасли специализации становятся все уже и глубже
- Специалист в NLP решает различные задачи получения, анализа, валидации и обработки текстовых данных



Задачи обработки естественного языка

Можно формулировать задачи с технической и продуктовой точек зрения

Технические задачи:

- Классификация
- ▶ POS-теггинг
- ▶ Извлечение сущностей
- Разрешение кореференции
- Лемматизация
- Сегментация
- Разметка семантических ролей
- Векторизация
- Машинный перевод
- **.**..

Продуктовые задачи:

- Анализ тональности
- Машинный перевод
- Генерация подписей к изображениям
- Генерация сниппетов для новостей
- Ведение диалога
- Исправление опечаток
- Поисковое и рекомендательное ранжирование
- Анализ трендов

Что нужно работодателю чаще всего

- Решать относительно простые и понятные задачи:
 - классификация (анализ тональности)
 - выделение сущностей (адреса, даты)
 - кластеризация (выделение интентов из логов)
 - трендовая аналитика
 - чат-боты
- Применять текстовые модели для задач предиктивной аналитики
- Создавать специализированные решения:
 - чит-чаты
 - машинный перевод
 - парафразирование
 - суммаризация
- ▶ В разных ситуациях как создавать собственное решение, так и искать + тестировать + внедрять готовое

Смежные специальности

- ▶ Разработчик ПО на Python/C++/Java/...
- Data-инженер
- ► MLops
- ▶ ML-инженер
- ▶ Специалист по машинному обучению
- ▶ Специалист по анализу данных
- Аналитик
- Product-менеджер
- ▶ Project-менеджер

Требования к NLP-специалистам

- Разнообразие задач и навыков порождает разнообразие вакансий и требований
- ▶ В ряде случаев работодатели не до конца представляют, какие именно задачи предстоит решать, и пишут в описание вакансии все подряд
- Иногда требования намеренно завышаются, что выбрать наиболее сильных и универсальных кандидатов
- Иногда, наоборот, описываются общими словами с минимальной конкретикой в описании инструментов и навыков
- Общеприняты три основных грейда: джуниор (junior), мидл (middle) и синьор (senior)
- ▶ В разных компаниях их понимание может отличаться радикально, но можно вывести некое усредненное представление

Базовые обязательные требования

- ▶ Технический английский язык (как минимум на уровне чтения)
- Базовая математическая подготовка:
 - линейная алгебра
 - математический анализ
 - теория вероятностей
 - математическая статистика
 - методы оптимизации
- Навыки программирования (как минимум на Python, в т.ч. в Jupyter Notebook)
- ▶ Базовые навыки работы в Unix/Linux-системах
- ▶ Умение самостоятельно искать нужную информацию в интернете

Требования к Junior

- ▶ Понимание постановок основных задач
- Умение работать с данными (поиск, предобработка, подсчёт статистик, выявление особенностей, поиск аномалий)
- Умение использовать методы ML и не-нейросетевые подходы (регулярные выражения, словари, правила, анализаторы)
- Понимание основных DL-архитектур, умение воспользоваться готовыми решениями по туториалам
- ▶ Понимание технических метрик качества и применимости их в различных задачах
- ▶ Навыки работы с репозиториями (версионирование, код ревью, СІ)
- ▶ Желательно: владение основами компьютерной лингвистики

Требования к Middle

- ▶ Опыт решения реальных индустриальных задач (хотя бы из базовых)
- Уверенное понимание основных задач в индустрии и подходов к их решению
- ▶ Использование DL-подходов, обучение и дообучение собственных моделей
- ▶ Понимание современных DL-архитектур, принципов их работы, преимуществ и недостатков
- Понимание основ статистической проверки гипотез и А/Б-тестов
- Умение работать с краудсорсингом и асессорами
- ▶ Уверенные навыки разработки на Python, владение ООП
- ▶ Знания об основных алгоритмах и структурах данных, их устройстве и сложностях
- ▶ Желательно: опыт разработки на не-скриптовых языках

Требования к Senior

- ▶ Многократный опыт решения разнообразных NLP-задач
- ▶ Глубокое понимание используемых подходов и моделей, как ML, так и DL
- ▶ Понимание предметной области, в которой ведется работа
- Умение для поставленной верхнеуровневой задачи сразу выстраивать поэтапный план ее решения, выбирать оптимальные гипотезы для проверки и оценивать предполагаемые результаты
- ▶ Понимание как технических, так и бизнес-метрик, умение выбирать нужные метрики и сопоставлять их друг с другом
- Привычка регулярно читать статьи о новых исследованиях и достижениях в области NLP, доносить их до коллег
- Желательно: умение взаимодействовать не только с коллегами из команды, но и со смежными специалистами, в т.ч. не техническими
- ► Желательно: иметь экспертизу в смежных областях (CV, RL, предиктивная аналитика)

Требования к Team Lead

- Умение организовать работу команды, состоящей из людей с различными уровнями и наборами компетенций
- Развитые софт-скиллы при общении с коллегами и с внешними контрагентами
- Умение представлять результаты работы команды перед вышестоящим начальством/заказчиками на понятном им языке и, наоборот, переводить их запросы в конкретные задачи для подчинённых
- Умение оценить перспективность решения/продукта «на берегу» с разных сторон
- ▶ Понимание устройства технических и бизнес процессов в компании хотя бы в рамках круга потребностей и задач своей команды

Направления роста NLP-специалиста

- За счёт широкого набора кругозора можно выбирать разные направления, например, переход
 - в исследовательские подразделения
 - ▶ в смежную DS/ML область
 - ▶ в MLOps
 - в разработку, в т.ч. на низкоуровневых языках
 - на руководящие посты
 - ▶ в project/product-менеджеры
 - в собственный бизнес
- Выбор не окончательный и может меняться многократно
- Иногда специалист может освоить сразу несколько направлений и одновременно решать в компании широкий спектр задач

Текущий статус индустрии обработки текстов

- ▶ В отличие от CV, в NLP после DL-революции классические подходы не потеряли полностью своей актуальности
- ► На локальном рынке много компаний, которые успешно используют подобные методы для решения базовых задач (напр. классификации)
- ► Но глобально лидирует подход Transfer Learning на основе больших предобученных моделей Transformer
- Архитектура Transformer из NLP оказалась настолько успешной, что активно модели на ее основе используются в CV и обработке сигналов
- В 2021 году мировой тренд на рост моделей развернулся:
 - модели становятся меньше в десятки раз
 - показатели качества остаются аналогичными за счет добавления возможности работы с базами данных для поиска нужной информации
 - ▶ пример: модель RETRO от DeepMind

Прогнозы на ближайшее будущее

Исходя из текущих тенденций, на ближайшее будущее намечается несколько трендов (список далеко не исчерпывающий):

- активное внедрение мультиязычных моделей, где перенос обучения позволяет уменьшить требования к объему данных на менее распространенных языках
- массовое распространение чит-чат болталок разного уровня в большом числе бизнесов, демократизация процесса их создания
- рост возможностей и бОльшая персонализация сервисов типа голосовых асситентов
- развитие интеграции NLP с технологиями виртуальной и дополненной реальности

Типы собеседований для NLP-специалистов

- Кодовая секция:
 - придумать алгоритм решения задачи
 - реализовать его на одном из подходящих языков программирования
- ▶ ML-секция:
 - ▶ ответить на набор вопросов про ML и DS
 - решить задачи на теорию вероятностей, логику или комбинаторику
 - часто проходит в формате «Представьте, что нужно создать такой-то сервис, как будете подходить к решению задачи?»
- ▶ DL/NLP-секция:
 - ответить на набор вопросов про DL, архитектуры, обучение
 - ответить на набор вопросов про нейросетевые модели (в т.ч. NLP)
 - часто проходит в формате «Расскажите про задачи, которые решали, чем пользовались?»

Вопрос:

- Какая структура данных лежит в основе контейнера set в Python?
- Какова сложность операции добавления элемента?
- Как еще можно реализовать такой контейнер?

Вопрос:

- Какая структура данных лежит в основе контейнера set в Python?
- Какова сложность операции добавления элемента?
- Как еще можно реализовать такой контейнер?

Ответ:

- В основе лежит хэш-таблица
- ightharpoonup Сложность добавления в обычном случае O(1), в худшем O(n)
- Реализовать можно с помощью бинарного дерева поиска

 Задача: для данной строки найти длину самой большой подпоследовательности из одного и того символа (aaadddaaabbbb -> 4)

- Задача: для данной строки найти длину самой большой подпоследовательности из одного и того же символа (aaadddaaabbbb -> 4)
- Решение:
 - Пройти по всей строке
 - Запоминать на каждом шаге длину текущего повторяющегося символа и длину самого длинного повторения
 - Обновлять наибольшую длину по мере необходимости
- ► Комментарий: это простая задача, но ее можно немного усложнить: то же условие, но символов два (aaadddaaabbbb -> 9)

► Задача: написать декоратор функции на Python, который печатает число раз, которое эта функция была вызвана

- ▶ Задача: написать декоратор функции на Python, который печатает число раз, которое эта функция была вызвана
- Решение:

```
def print_num_calls(f):
    i = 0
    def _f(*args, **kwargs):
        nonlocal i
        print(i := i + 1)
        return f(*args, **kwargs)
    return _f
```

▶ Вопрос: является ли Python языком со строгой типизацией или нет?

- ▶ **Bonpoc**: является ли Python языком со строгой типизацией или нет?
- Ответ:
 - ▶ Да, Python строго типизированный язык
 - Важно не путать объекты и переменные, которые являются ссылками на объекты

```
a = 1
2 a = 's'
```

- Переменные могут легко присваиваться разным объектам
- Объект же имеет один тип и не меняет его на протяжении всего жизненного цикла

- **Bonpoc**: представим, что требуется создать сервис для кредитного скоринга
 - Как подходить к решению этой задачи?
 - Какие данные могут понадобиться?
 - ▶ Как будет измеряться качество решения?

- ▶ Вопрос: представим, что требуется создать сервис для кредитного скоринга
 - Как подходить к решению этой задачи?
 - Какие данные могут понадобиться?
 - Как будет измеряться качество решения?

Ответ:

- Общая идея: собираем исторические данные и обучаем ML-модель.
- ▶ Объемы кредитов, признаки заемщиков, успешность возвращения
- В простейшем случае доля верных предсказаний

▶ Вопрос: какие именно признаки заемщиков могут оказаться полезными?

- ▶ Вопрос: какие именно признаки заемщиков могут оказаться полезными?
- Ответ:
 - ▶ Объем средств на счетах
 - Суммарный объем и число кредитов
 - Регулярность и объем пополнений счетов
 - Город и район прописки/проживания
 - Пол, возраст
 - **.**..

▶ Вопрос: в данном случае у нас задача бинарной классификации, поэтому можно измерять долю верных ответов. А в каких случаях эта метрика качества плоха? Какие еще есть метрики для этой задачи? А для регрессии?

▶ Вопрос: в данном случае у нас задача бинарной классификации, поэтому можно измерять долю верных ответов. А в каких случаях эта метрика качества плоха? Какие еще есть метрики для этой задачи? А для регрессии?

Ответ:

- Доля верных ответов для классификации подойдет плохо, если выборка существенно не сбалансирована
- Альтернатива точность/полнота и их гармоническое среднее (F-мера)
- ▶ Для регрессии есть множество метрик, наиболее популярные MAE, MSE, RMSE
- **Комментарий:** обычно еще требуется расписать эти метрики и объяснить, чем одна отличается от другой

Bonpoc: было сказано об ML-моделях. Какие модели стоит попробовать использовать?

▶ **Bonpoc**: было сказано об ML-моделях. Какие модели стоит попробовать использовать?

Ответ:

- ▶ В первую очередь стоит обучить лог-регрессию, это простой и сильный бейзлайн
- Сильным решением получится градиентный бустинг над решающими деревьями
- Комментарий: обязательно спросят про то, что представляют собой оба подхода

▶ **Bonpoc**: что такое «регуляризация»? Какие виды регуляризации и используются при обучении лог-регрессии и почему? К какому эффекту они приводят?

▶ **Bonpoc**: что такое «регуляризация»? Какие виды регуляризации и используются при обучении лог-регрессии и почему? К какому эффекту они приводят?

Ответ:

- ▶ Регуляризация ограничивает область возможных значений весов модели
- В лог-регрессии используются математические подходы (L_1 , L_2 и ElasticNet) и ранний останов
- В отсутствие регуляризации лог-регрессия сильно переобучается, устремляя все веса в $\pm\infty$
- $ightharpoonup L_1$ -регуляризация зануляет часть весов, L_2 делает все веса небольшими по модулю
- L_2 -регуляризация лучше справляется с коррелированными признаками (веса распределяются пропорционально, а не случайно, как в L_1)

Bonpoc: каким образом можно распараллелить обучение градиентного бустинга?

Bonpoc: каким образом можно распараллелить обучение градиентного бустинга?

Ответ:

- Градиентный бустинг нельзя распараллелить по деревьям
- ▶ Но можно распараллелить по ядрам процесс обучения одного дерева, например, по признакам внутри одного узла дерева

▶ Вопрос: Предположим, что модель была обучена и отправлена в работу. Как проверить, что она работает лучше, чем люди?

► **Bonpoc**: Предположим, что модель была обучена и отправлена в работу. Как проверить, что она работает лучше, чем люди?

- В идеале нужно провести А/Б-тест, выделив репрезентативные выборки под оба метода
- С учётом того, что кредит будет выплачиваться долго, можно пробовать более краткосрочные метрики, например, просрочку по первым 2-3 платежам
- **Комментарий:** скорее всего спросят про то, как сравнить результаты двух подходов с помощью статистических критериев

▶ Вопрос: из чего состоит чат-бот?

- ▶ Вопрос: из чего состоит чат-бот?
- Ответ:
 - ▶ Большинство чат-ботов состоит из классификатора интентов, NER и сценарного графа
 - ▶ В случае чит-чата могут использоваться генеративные и IR-модели
- ► Комментарий: здесь могут уточнить про разницу между NER и slot-filling, а также про детали работы сценарного графа

Вопрос: предположим, что ставится задача классификации текстов, и выдана выборка размеченных текстов. Что будете делать с данными до обучения моделей?

Bonpoc: предположим, что ставится задача классификации текстов, и выдана выборка размеченных текстов. Что будете делать с данными до обучения моделей?

- ▶ Первый шаг анализ. Подсчет основных статистик по объектам и классам, анализ словаря
- Второй шаг предобработка и генерация признаков
- **Комментарий:** имеет смысл уточнить, какие именно статистики и зачем считаются, когда нужна предобработка, какие признаки можно генерировать

• **Bonpoc**: предположим, что для классификации текстов есть только неразмеченная выборка. Как можно получить разметку?

- ► **Bonpoc**: предположим, что для классификации текстов есть только неразмеченная выборка. Как можно получить разметку?
- Ответ:
 - самостоятельная ручная разметка (обязательна!)
 - разметка с помощью правил, словарей и регулярных выражений
 - разметка с помощью краудсорсинга (например, Яндекс.Толока)
 - для краудсорсинга может потребоваться активное обучение, его можно сделать с помощью простой модели
 - можно использовать аугментацию данных (синонимы, замены/удаления, SMOTE)
- **Комментарий:** в случае задачи с большим числом классов может потребоваться последовательное повторение шагов для разных уровней агрегации классов

Bonpoc: рассказать про постановку задачи NER и существующие подходы к ее решению

▶ Вопрос: рассказать про постановку задачи NER и существующие подходы к ее решению

- № NER задача извлечения именованных сущностей (адреса, телефоны, геолокации, имена, числа)
- Базовый метод решения правила, словари и регулярные выражения
- В нейросетевой постановке это задача разметки последовательности, раньше ее решали с помощью RNN, теперь основной подход – модели на основе кодировщика трансформера

▶ Вопрос: как устроена сверточная сеть для классификации текстов?

- ▶ Вопрос: как устроена сверточная сеть для классификации текстов?
- Ответ:
 - Для классификации текстов обычно используют однослойные CNN с одномерными свертками
 - Вход сети матрица из эмбеддингов (слово за словом)
 - Одномерные свертки разных размеров двигаются по ней сверху вниз (вторая размерность такая же, как у эмбеддингов)
 - На выходе слоя набор векторов-карт признаков разного размера.
 - К ним применяется пулинг для получения итогового вектора фиксированного размера
 - ▶ Этот вектор передается в полносвязные слои и softmax
- **Комментарий:** можно рассказать про смысл использования сверток разных размеров и типы пулинга

▶ **Bonpoc**: в чём заключается преимущество модели векторных представлений FastText перед word2vec или GloVe?

▶ **Bonpoc**: в чём заключается преимущество модели векторных представлений FastText перед word2vec или GloVe?

- ► FastText одновременно с векторами слов и словарных n-грамм обучает векторы символьных n-грамм
- Это позволяет получать векторы для OOV-слов с помощью суммы векторов входящих в них символьных n-грамм
- ▶ В более ранних моделях проблема OOV обычно решалась введением UNK-токена, что существенно хуже
- ► Также у FastText есть очень эффективная параллельная реализация на CPU

▶ **Bonpoc**: как устроен слой self-attention в архитектуре Transformer? Есть ли в нем нелинейность?

▶ **Bonpoc**: как устроен слой self-attention в архитектуре Transformer? Есть ли в нем нелинейность?

- Слой параметризован тремя весовыми матрицами
- Каждый вектор входной последовательности перемножается со всеми тремя матрицами
- Для каждого токена получается три вектора: ключи, запросы и значения
- ► Набор коэффициентов для токена получается умножением его вектора запроса на все векторы ключей (+ softmax и нормировка)
- Итоговый вектор для токена получается как взвешенная с этими коэффициентами сумма векторов значений
- Нелинейности в нем нет (она есть дальше после полносвязного слоя)

▶ Bonpoc: Как в слое self-attention использовать авторегрессионность?

- ▶ Bonpoc: Как в слое self-attention использовать авторегрессионность?
- Ответ: Достаточно занулять коэффициенты, связанные с маскированными токенами

▶ Вопрос: Какое потребление памяти на этапе инференса у RNN и BERT?

- ▶ Вопрос: Какое потребление памяти на этапе инференса у RNN и BERT?
- Ответ:
 - \triangleright RNN O(1)
 - ▶ BERT $O(n^2)$, n длина последовательности
- ► Комментарий: в стандартном self-attention нужно хранить матрицу коэффициентов для каждой пары токенов входа

▶ Boпрос: в чем главные идеи моделей ALBERT и ELECTRA?

▶ Вопрос: в чем главные идеи моделей ALBERT и ELECTRA?

- ▶ Модель ALBERT экономит память за счет разделения весов между блоками кодировщика трансформера
- ▶ В модели ELECTRA (в основе BERT) реализуется идея GAN: обучаются две Transformer-подобные модели, генератор и дискриминатор
- ▶ Генератор небольшая модель, вставляющая на место токенов [MASK] последовательности свои варианты
- Дискриминатор основная модель, которая учится предсказывать, какие токены являются замененными
- ▶ Такая процедура обучения позволяет улучшить качество предобучения по сравнению с обычным MLM

Какие еще бывают вопросы

- ▶ Есть важные вопросы, не касающиеся напрямую технических навыков, с ростом грейда их количество растет:
 - Есть ли опыт руководства командой, какой численности?
 - Как была устроена работа в командах, какие процессы?
 - Был ли опыт построения решения end-to-end от бизнес постановки до внедрения и сопровождения? Если был, то какой?
 - Есть ли опыт взаимодействия с внутренними или внешними бизнес-заказчиками?
 - Какой самый интересный/сложный проект удавалось реализовать в роли исполнителя/руководителя?

Какие ошибки встречаются на NLP-собеседованиях

- ▶ Отсутствие части компетенций (математика, программирование)
- Написание существенно неоптимального кода при решении задач
- ▶ Перекос знаний и навыков в сторону DL (или, наоборот, в сторону классических подходов и моделей)
- Kaggle-подход: игнорирование при проектировании решения технических проблем, связанных с будущей эксплуатацией решения
- ▶ Непонимание того, что работа с данными является часто важнее и затратнее непосредственного обучения моделей
- Неумение описать свой вклад в сделанные ранее проекты